

# 内 容 简 介

本书记录了作者在山大数院的三年所学的数学知识，简明扼要地列举出每个学科所必须掌握的定理等重要知识点。此书不宜作为初学某一科目的参考资料，而适合已学完部分内容者查漏补缺。

根据山大本科开课顺序以及个人自学进度，大致收录下列学科：

大一上：数学分析 1，高等代数 1，解析几何

大一下：数学分析 2，高等代数 2

大二上：数学分析 3，复变函数，常微分方程

大二下：实变函数，偏微分方程，概率论

大三上：机器学习、数字图像处理、数理统计、矩阵论

大三下：时间序列分析、数据库系统、数据结构

# 目 录

第一章 概率论与数理统计	1
1.1 随机事件与概率	2
1.1.1 随机事件	2
1.1.2 概率	2
1.1.3 概率的性质	3
1.1.4 条件概率	3
1.2 随机变量及其分布	4
1.2.1 随机变量	4
1.2.2 常用分布及概率密度函数	5
1.2.3 数字特征	5
1.2.4 随机变量函数的分布	6
1.3 多元随机变量及其分布	6
1.3.1 多元随机变量	6
1.3.2 边缘分布	7
1.3.3 多元随机变量函数的分布	8
1.3.4 多元随机变量的特征数	8
1.3.5 条件分布与条件期望	9

---

1.4	大数定律和中心极限定理 . . . . .	10
1.4.1	随机变量的特征函数 . . . . .	10
1.4.2	大数定律 . . . . .	10
1.4.3	中心极限定理 . . . . .	11

# 第一章 概率论与数理统计

## Mathematical Analysis

概率论与数理统计是由数分高代派生出来的应用学科,用于刻画日常生活中随机发生的事件,具有很高的应用价值. 其中,概率论主要研究随机变量的分布与特征,而数理统计主要研究通过样本对未知分布进行估计.

概率论的重点: 概率的定义, 条件概率与独立性, 一元或多元随机变量分布, 常用分布函数, 随机变量的特征数, 大数定律和中心极限定理

数理统计的重点: 基本概念与三大分布, 参数估计, 假设检验, 方差分析, 回归分析

## 1.1 随机事件与概率

之前数学分析研究的内容都是具有确定解析式或约束条件的函数, 但概率论引进了随机因素, 即实验和结果并不是一一对应的, 一次实验可能会出多种结果. 这一部分的任务是使用概率这一量化方式, 将随机性规范化.

### 1.1.1 随机事件

1. 随机现象: 重复实验会出现不同结果的现象.
2. 样本空间: 随机现象可能出现的结果组成的集合.
3. 随机事件: 样本空间的子集. 当实验结果属于此子集时, 称随机事件发生.
4. 随机变量: 用于描述随机事件的人为设定变量 (非正式定义).
5. 事件的运算: 和集合一致, 有交并补余四大运算. 有两个公式很重要.
  - (1) 集合减法公式:  $A - B = A \cap \bar{B}$ .
  - (2) 德摩根律:  $\overline{A \cup B} = \bar{A} \cap \bar{B}; \overline{A \cap B} = \bar{A} \cup \bar{B}$ .
6. 事件域: 令  $\Omega$  为样本空间, 定义事件域  $\mathcal{F}$  符合下列性质:

- (1)  $\Omega \in \mathcal{F}$ ; (2)  $A \in \mathcal{F} \Rightarrow \bar{A} \in \mathcal{F}$ ; (3)  $A_n \in \mathcal{F} \Rightarrow \bigcup_{n=1}^{\infty} A_n \in \mathcal{F}$ .

### 1.1.2 概率

1. 公理化定义: 在事件域  $(\Omega, \mathcal{F})$  上定义可测函数  $P(A)$  满足:
  - (1) 非负性:  $P(A) \geq 0$ ; (2) 正则性:  $P(\Omega) = 1$ ;
  - (3) 可列可加性: 事件  $A_1, \dots, A_n$  互不相容时,  $P(\bigcup_{n=1}^{\infty} A_n) = \sum_{n=1}^{\infty} P(A_i)$ .
2. 用频率定义概率: 令  $n(A)$  为事件  $A$  发生的频数, 则可用大量重复事件的频率表示概率:  $P(A) = \lim_{n \rightarrow \infty} \frac{n(A)}{n}$ .

3. 古典概型: 若样本空间有  $n$  个等可能发生的样本点, 则事件  $A$  包含  $k$  个样本点时,  $P(A) = \frac{k}{n}$ .

4. 几何概型: 若样本空间  $\Omega$  的面积测度为  $S_n$ , 事件  $A$  包含其中面积为  $S_A$  的一部分, 则  $P(A) = \frac{S_A}{S_n}$ . (蒙特卡罗法的理论依据)

5. 贝叶斯概率: 对事件发生可能性的主观预测, 在机器学习中使用频率很高.

### 1.1.3 概率的性质

1. 有限可加性: 若  $A_1, \dots, A_n$  互不相容, 则  $P(\bigcup_{i=1}^n A_i) = \sum_{i=1}^n P(A_i)$ .
2. 单调性: 若  $A \subset B$ , 则  $P(A) \leq P(B)$ .
3. 加法公式:  $P(A \cup B) = P(A) + P(B) - P(AB)$ .

### 1.1.4 条件概率

1. 定义:  $P(A|B)$  表示已知  $B$  发生的条件下  $A$  发生的概率.  $P(A|B) = \frac{P(AB)}{P(B)}$ .
2. 乘法公式:  $P(AB) = P(B)P(A|B)$ , 即定义式的变种.
3. 全概率公式: 若  $B_i$  互不相容, 且  $\bigcup_{i=1}^n B_i = \Omega$ , 则

$$P(A) = \sum_{i=1}^n P(A|B_i)P(B_i)$$

4. 贝叶斯公式: 用先验概率推后验概率. 若  $B_i$  互不相容, 且  $\bigcup_{i=1}^n B_i = \Omega$ , 则

$$P(B_i|A) = \frac{P(A|B_i)P(B_i)}{\sum_{k=1}^n P(A|B_k)P(B_k)}$$

5. 独立性: 若  $P(A|B) = P(A)$ , 即  $P(AB) = P(A)P(B)$ , 则称事件  $A$  和  $B$  相互独立.

## 1.2 随机变量及其分布

用概率描述随机事件发生可能性的大小后, 为了更充分认识随机事件, 我们引入随机变量来刻画随机事件, 如抽奖是随机事件, 在此基础上可以定义随机变量“是否中奖”, 这是一个二值随机变量 (0/1).

使用随机变量来描述随机事件, 能更方便地研究随机事件中我们感兴趣的性质, 比如随机变量“灯泡坏掉的个数”能帮助我们衡量灯泡的寿命. 这些随机变量取值的规律可以用分布来描述, 离散随机变量和连续随机变量的刻画方式略有区别.

### 1.2.1 随机变量

1. 定义: 样本空间  $\Omega$  上的实值函数  $X(\omega)$ .
2. 离散随机变量的确定: 使用分布列描述.

$X$	$X_1$	$X_2$	$\cdots$	$X_n$
$P$	$p_1$	$p_2$	$\cdots$	$p_n$

其中  $p_i$  表示随机变量  $X$  取值  $X_i$  的概率,  $\sum_{i=1}^n p_i = 1$ .

3. 连续随机变量的描述: 使用分布函数与概率密度函数.

(1) 分布函数  $F(x)$ :  $F(x) = P(X \leq x)$ , 是单调递增的右连续函数, 且  $F(+\infty) = 1, F(-\infty) = 0$ .

(2) p.d.f 概率密度函数  $p(x)$ :  $p(x) = F'(x)$ , 是非负函数且  $\int_{-\infty}^{+\infty} p(x)dx = 1$ .

## 1.2.2 常用分布及概率密度函数

### 1. 离散分布

(1) 泊松分布:  $P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}$ , 用于计数过程, 记作  $X \sim P(\lambda)$ .

(2) 伯努利分布:  $P(X = 1) = p, P(X = 0) = 1 - p$ , 又称两点分布.

(3) 二项分布:  $P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$ , 即  $n$  重伯努利分布中事件发生的次数, 记作  $X \sim b(n, p)$ .

(4) 几何分布:  $P(X = k) = (1 - p)^{k-1} p$ , 具有无记忆性.

### 2. 连续分布

(1) 正态分布:  $p(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$ , 是最常用的分布. 记作  $X \sim N(\mu, \sigma^2)$ , 标准正态分布即  $N(0, 1)$ .

(2) 均匀分布:  $p(x) = \frac{1}{b-a}$ , 其中  $x \in (a, b)$ , 记作  $X \sim U(a, b)$ .

(3) 指数分布:  $p(x) = \lambda e^{-\lambda x}$ , 其中  $x \geq 0$ , 记作  $X \sim \epsilon(\lambda)$ , 具有无记忆性.

(4) 伽马分布:  $p(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}$ , 其中  $x \geq 0$ , 记作  $X \sim Ga(\alpha, \lambda)$ . 特殊地,  $Ga(\frac{n}{2}, \frac{1}{2}) = \chi^2(n)$  为卡方分布, 统计中常用.

## 1.2.3 数字特征

1. 数学期望:  $X$  在不同取值数按概率的加权平均数, 是消除随机性的主要手段, 记作  $Ex$ . 在离散场合,  $EX = \sum_{n=1}^{\infty} p_i x_i$ . 在连续场合,  $EX = \int_{-\infty}^{+\infty} xp(x)dx$ .

2. 方差:  $DX = E[(X - EX)^2]$ , 也记作  $\text{Var}(X)$ , 用于衡量数据的集中程度. 常用的计算公式为

$$DX = E(X^2) - (EX)^2$$

3. 标准差:  $\sigma(x) = \sqrt{DX}$ , 也记作  $Std(X)$ , 好处是与  $X$  的量纲一致.



4. 切比雪夫不等式:  $P(|X - EX| \geq \text{textVarepsilon}) \leq \frac{DX}{\text{textVarepsilon}^2}$ .

## 1.2.4 随机变量函数的分布

1. 离散情形: 先求各项的像  $g(x_1), \dots, g(x_n)$ ,  $g(x_i)$  对应概率仍为  $p_i$ , 再合并相同项.

2. 连续情形: 若  $Y = g(x)$  严格单调, 反函数为  $x = h(y)$ ,  $X$  的概率密度函数为  $p(x)$ , 则  $Y$  的概率密度函数为  $p_Y(y) = p_X(h(y)) \cdot |h'(y)|$ . 一般情况下, 需要根据  $P(g(x) \leq y)$  反解出  $x$  的范围, 再利用  $X$  的分布函数求解.

## 1.3 多元随机变量及其分布

若样本点含有不止一个我们感兴趣的属性, 如身体指标包含身高和体重, 则可定义多元随机变量来刻画这些指标的分布. 研究多元随机变量, 除了明确各分量的分布外, 还需要研究各分量间的相关关系, 以及给定某条件后的分布情况.

事实上, 只要给定多元随机变量的联合分布, 就能得到所有信息, 该部分的目的就是掌握将信息从联合分布中提取出来的方法.

### 1.3.1 多元随机变量

1. 定义: 样本空间  $\Omega$  上的向量值函数  $X(\omega) = (X_1(\omega), \dots, X_n(\omega))$ .
2. 联合分布函数:  $F(x_1, \dots, x_n) = P(X_1 \leq x_1, \dots, X_n \leq x_n)$

3. 离散情形的联合分布列: 仅用于二元分布  $(X, Y)$ , 用  $i$  行  $j$  列元素  $p_{ij}$  表示  $X = X_i, Y = Y_j$  的概率, 其中  $\sum_{i,j} p_{ij} = 1$ .

4. 连续情形的联合密度函数:  $p(x_1, \cdots, x_n) = \frac{\partial^n F(x_1, \cdots, x_n)}{\partial x_1 \partial x_2 \cdots \partial x_n}$ .

5. 多元正态分布: 最重要的多元连续分布. 令  $x = (x_1, \cdots, x_n)$ , 均值向量为  $\mu$ , 协方差矩阵为  $\Gamma$ , 则  $n$  元正态分布的联合密度函数

$$p(x_1, \cdots, x_n) = \frac{1}{(2\pi)^{\frac{n}{2}} |\Gamma|^{\frac{1}{2}}} e^{-\frac{1}{2}(x-\mu)^T \Gamma^{-1} (x-\mu)}$$

特殊地, 当  $n = 2$  时, 二元正态分布为

$$p(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)}[(\frac{x-\mu_1}{\sigma_1})^2 - 2\rho\frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + (\frac{y-\mu_2}{\sigma_2})^2]}$$

记作  $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ .

### 1.3.2 边缘分布

1. 边缘分布函数:  $F_x(x) = F(x, \infty), F_y(y) = F(\infty, y)$ .
2. 离散情形的边缘分布列:  $P(X = X_i) = \sum_j P(X = X_i, Y = Y_j); P(Y = Y_j) = \sum_i P(X = X_i, Y = Y_j)$
3. 连续情形的边缘密度函数:  $p_X(x) = \int_{-\infty}^{\infty} p(x, y) dy; p_Y(y) = \int_{-\infty}^{\infty} p(x, y) dx$ .
4. 随机变量的独立性: 若  $\prod_{i=1}^n p_i(X_i) = p(x_1, \cdots, x_n)$ , 即联合密度函数为边缘密度函数之积, 则称  $X_1, \cdots, X_n$  相互独立.

### 1.3.3 多元随机变量函数的分布

1.  $Z = X + Y$  的分布: 可用后面提到的特征函数法, 也可用卷积公式, 即  $p_Z(z) = \int_{-\infty}^{\infty} p_X(x)p_Y(z-x)dx$ .

2. 次序统计量分布: 若  $X_{(1)}, \dots, X_{(n)}$  独立同分布且升序排列, 则第  $k$  个次序统计量  $X_{(k)}$  的概率密度函数为

$$p_{(k)}(x) = \frac{n!}{(k-1)!(n-k)!} [F(x)]^{k-1} p(x) [1-F(x)]^{n-k}$$

特殊地,  $\min X$  即  $X_{(1)}$  的概率密度函数为  $n[1-F(x)]^{n-1}p(x)$ ;  $\max X$  即  $X_{(n)}$  的概率密度函数为  $n[F(x)]^{n-1}p(x)$ .

3. 变量变换法: 令  $u = u(x, y), v = v(x, y)$ , 从中反解出  $x = x(u, v), y = y(u, v)$ , 则  $p(u, v) = p(x, y) \left| \frac{\partial(x, y)}{\partial(u, v)} \right|$ .

### 1.3.4 多元随机变量的特征数

1. 数学期望:  $g(x, y)$  的期望为  $\int_R g(x, y)p(x, y)dxdy$ .

2. 方差: 定义不变, 仍有  $\text{Var}(x) = E(X - EX), \text{Var}(y) = E(Y - EY)$ .

3. 协方差:  $\text{Cov}(X, Y) = E[(X - EX)(Y - EY)] = E(XY) - EXEY$ , 用于刻画两变量的相关程度.

4. 相关系数:  $\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)}\sqrt{\text{Var}(Y)}}$ . 当  $\text{Corr}(x) \in (0, 1]$  时, 称  $X$  和  $Y$  正相关;  $\text{Corr}(x) \in [-1, 0)$  时, 称  $X$  和  $Y$  负相关;  $\text{Corr}(x) = 0$  时, 称  $X$  和  $Y$  不相关.

5. 方差运算性质:  $\text{Var}(X \pm Y) = \text{Var}(X) + \text{Var}(Y) \pm 2\text{Cov}(X, Y)$

6.  $n$  元随机变量的协方差矩阵:

$$\Gamma = \begin{pmatrix} \text{Cov}(X_1, X_1) & \text{Cov}(X_1, X_2) & \cdots & \text{Cov}(X_1, X_n) \\ \text{Cov}(X_2, X_1) & \text{Cov}(X_2, X_2) & \cdots & \text{Cov}(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_n, X_1) & \text{Cov}(X_n, X_2) & \cdots & \text{Cov}(X_n, X_n) \end{pmatrix}$$

用于刻画各分量之间的总体相关性.

### 1.3.5 条件分布与条件期望

1. 离散条件分布:  $P_{i|j} = P(X = X_i | Y = y_j) = \frac{p_{ij}}{\sum_i p_{ij}}$ .

2. 连续条件分布:  $p(y|x) = \frac{p(x,y)}{p_X(x)}$ ;  $p(x|y) = \frac{p(x,y)}{p_Y(y)}$

3. 全概率公式:  $p_Y(y) = \int_{-\infty}^{\infty} p_X(x)p(y|x)\mathrm{d}x$ .

4. 贝叶斯公式:

$$p(x|y) = \frac{p(y|x)p_X(x)}{\int_{-\infty}^{\infty} p(y|x)p_X(x)\mathrm{d}x}$$

5. 条件数学期望:  $E(X|Y = y) = \int_{-\infty}^{\infty} xp(x|y)\mathrm{d}x$ .

6. 重期望公式:  $E[E(X|Y)] = EX$ .

## 1.4 大数定律和中心极限定理

这部分首先将傅里叶变换引入概率密度函数的求解中, 得到特征函数这个很好用的工具, 再借助特征函数推导大数定律和中心极限定理的一般结论, 为数理统计的展开做好铺垫.

大数定律的内容很简单, 就是抽样次数足够大时, 频率近似于概率, 均值近似于数学期望, 这给大样本统计提供了理论依据. 中心极限定理说明多个独立同分布随机变量之和近似于正态分布, 这鼓励我们在大样本统计中使用正态分布进行统计推断.

### 1.4.1 随机变量的特征函数

1. 定义:  $\varphi(t) = E(e^{itX})$ . 离散情形下,  $\varphi(t) = \sum_{k=1}^{\infty} p_k e^{itX_k}$ ; 连续情形下,  $\varphi(t) = \int_{-\infty}^{\infty} p(x) e^{itx} dx$ .

2. 性质: (1) 若  $X$  与  $Y$  独立,  $Z = X + Y$ , 则  $\varphi_Z(t) = \varphi_X(t) \cdot \varphi_Y(t)$ .

(2) 求各阶矩的方式:  $\varphi^{(k)}(0) = i^k E(X^k)$ .

(3) 唯一性定理: 分布函数由特征函数唯一确定.

3. 逆转公式:  $F(x_2) - F(x_1) = \lim_{T \rightarrow +\infty} \frac{1}{2\pi} \int_{-T}^T \frac{e^{-itx_1} - e^{-itx_2}}{it} \varphi(t) dt$ .

4. 连续随机变量的逆变换公式:  $p(x) = \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{-itx} \varphi(t) dt$ .

### 1.4.2 大数定律

1. 一般形式: 对任意  $\varepsilon > 0$ , 有

$$\lim_{n \rightarrow +\infty} P \left( \left| \frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n EX_i \right| < \varepsilon \right) = 1$$

2. 伯努利大数定律: 令  $S_n$  为  $n$  重伯努利试验中事件发生的次数,  $p$  为事件发生的概率, 则对任意  $\varepsilon > 0$ , 有

$$\lim_{n \rightarrow +\infty} P\left(\left|\frac{S_n}{n} - p\right| < \varepsilon\right) = 1$$

3. 切比雪夫大数定律: 当  $\{X_n\}$  两两不相关且  $Var(X_i)$  有界时, 大数定律成立.

4. 辛钦大数定律: 当  $X_1, \dots, X_n$  独立同分布且  $EX_i$  存在时, 大数定律成立.

5. 辛钦大数定律的证明: 令  $\varphi(t)$  为  $X_i$  共同的特征函数, 数学期望为  $a$ , 将  $\varphi(t)$  在  $t = 0$  处泰勒展开:  $\varphi(t) = 1 + iat + o(t)$ . 故  $\varphi_{\frac{1}{n} \sum_{i=1}^n X_i}(t) = [\varphi(\frac{t}{n})]^n \sim e^{iat}$ , 恰是退化分布的特征函数.

### 1.4.3 中心极限定理

1. 林德伯格-莱维中心极限定理: 令  $X_n$  独立同分布,  $EX_i = \mu$ ,  $DX_i = \sigma^2$ , 则  $n \rightarrow \infty$  时,  $\frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}}$  的分布弱收敛于标准正态分布.

2. 蒂莫夫-拉普拉斯中心极限定理: 令  $S_n$  为  $n$  重伯努利试验中事件发生的次数,  $p$  为事件发生的概率, 则  $\frac{S_n - np}{\sqrt{np(1-p)}}$  在  $n \rightarrow \infty$  时的分布弱收敛于标准正态分布.

3. 中心极限定理证明: 将  $X_i$  标准化:  $Y_i = \frac{X_i - \mu}{\sigma}$ , 则  $EY_i = 0$  且  $DY_i = 1$ . 令  $Y_N$  的特征函数为  $\varphi(t)$ , 故  $\frac{1}{\sqrt{n}} \sum_{i=1}^n Y_i$  的特征函数为  $\left[\varphi\left(\frac{t}{\sqrt{n}}\right)\right]^n$ . 由泰勒展开:  $\varphi\left(\frac{t}{\sqrt{n}}\right) = 1 - \frac{t^2}{2n} + o(t^2)$ , 在  $n \rightarrow \infty$  时,  $\frac{1}{\sqrt{n}} \sum_{i=1}^n Y_i$  的特征函数趋近于  $e^{-\frac{t^2}{2}}$ , 恰为  $N(0, 1)$  的特征函数.